MVP - Engenharia de Dados

Aluno: Vinícius Mergulhão da Silva

1. Visão Geral

Este projeto foi desenvolvido como um MVP de Engenharia e Análise de Dados utilizando o **Databricks**, com o objetivo de construir uma estrutura de dados organizada, confiável e preparada para análises de negócio a partir de um conjunto de dados transacionais de vendas.

O projeto percorre as principais etapas de um fluxo de dados moderno: ingestão dos dados brutos, armazenamento em camada Bronze, tratamento e validação na camada Silver, modelagem dimensional na camada Gold, aplicação de controles de qualidade e, finalmente, realização das análises de negócio.

A implementação foi realizada predominantemente utilizando **SQL no Databricks**, buscando demonstrar a construção de um pipeline de dados completo sem dependência desnecessária de código externo.

2. Contexto de Negócios e Perguntas (Etapa 2 e 4.1)

2.1 Contexto do negócio

O objetivo do projeto é desenvolver uma estrutura de dados confiável e escalável para analisar o desempenho das vendas de um e-commerce.

A proposta é transformar dados transacionais brutos em uma estrutura organizada, documentada e adequada para consultas analíticas, permitindo identificar padrões relacionados à receita transacionada, produtos, clientes, descontos, métodos de pagamento, vendedores e status dos pedidos.

O problema de negócio pode ser resumido da seguinte forma:

> **Como transformar dados transacionais de vendas em uma estrutura de dados confiável e organizada que permita analisar o desempenho comercial do e-commerce e apoiar a tomada de decisões baseada em dados?**

Para solucionar esse problema, foi construída uma arquitetura em camadas, contemplando ingestão, tratamento, validação, modelagem dimensional e análise.

2.2 Perguntas de negócio

As etapas posteriores do projeto foram orientadas pelas seguintes perguntas:

Pergunta 1 — Evolução das vendas

Como a receita e o volume de pedidos evoluem ao longo do tempo?

Foram analisados indicadores como quantidade de pedidos, unidades vendidas, valor total das transações e ticket médio, considerando diferentes períodos de tempo.

Pergunta 2 — Produtos

Quais categorias, marcas e produtos apresentam maior volume e valor de vendas?

A análise busca identificar quais grupos de produtos concentram maior quantidade de unidades comercializadas e maior valor transacionado.

Pergunta 3 — Descontos

Como diferentes níveis de desconto estão associados ao volume e ao valor das vendas?

Os pedidos foram agrupados em faixas de desconto para comparar quantidade de pedidos, unidades vendidas, valor transacionado e ticket médio.

É importante destacar que a análise identifica **associações**, não relações causais. Portanto, um determinado nível de desconto apresentar maior volume de vendas não significa, por si só, que o desconto tenha causado esse resultado.

Pergunta 4 — Composição das transações

Como preço, quantidade, desconto, impostos e frete se relacionam com o valor total das transações?

Essa análise busca compreender a composição dos valores registrados no dataset e verificar a consistência matemática entre os componentes da transação e o TotalAmount.

Pergunta 5 — Clientes e localização

Como as vendas se distribuem entre clientes e localizações geográficas?

Foram analisados clientes, países, estados e cidades, considerando volume de pedidos e valor transacionado.

Pergunta 6 — Status dos pedidos

Como os diferentes status dos pedidos se distribuem e qual sua relação com o valor das transações?

Foram analisados os diferentes status registrados na base, comparando quantidade de pedidos, unidades e valores associados.

Pergunta 7 — Métodos de pagamento

Quais métodos de pagamento são utilizados e como eles se relacionam com o volume e o valor das transações?

A análise compara os métodos de pagamento em relação ao número de pedidos, unidades comercializadas e valor transacionado.

Pergunta 8 — Vendedores

Como o desempenho das vendas se distribui entre os vendedores?

Foram analisados os vendedores considerando volume de pedidos, quantidade de unidades, valor transacionado e ticket médio.

2.3 Contexto e estrutura dos dados brutos

O dataset utilizado foi o **Amazon Sales Dataset**, disponibilizado no Kaggle por Rohit Kumar.

A base contém **100.000 registros e 20 atributos**, representando transações de vendas de um e-commerce.

Os principais grupos de informações são:

Grupo	Atributos
Pedido	OrderID, OrderDate, OrderStatus
Cliente	CustomerID, CustomerName, City, State, Country
Produto	ProductID, ProductName, Category, Brand
Venda	Quantity, UnitPrice, Discount, Tax, ShippingCost, TotalAmount

Pagamento	PaymentMethod
Vendedor	SellerID

A base possui dados referentes ao período de **01/01/2020 a 29/12/2024**.

Na análise inicial foram identificados:

- 100.000 registros;
- 20 atributos;
- 100.000 OrderID distintos;
- ausência de registros completamente duplicados;
- ausência de valores nulos nos atributos originais;
- 43.233 clientes distintos;
- 50 produtos distintos;
- 1.999 vendedores distintos;
- 6 categorias;
- 10 marcas;
- 6 métodos de pagamento;
- 5 status de pedidos.

O dataset é apresentado como um conjunto de dados **sintético**. Dessa forma, os resultados encontrados neste projeto devem ser interpretados como resultados analíticos sobre o dataset utilizado e não como representação do comportamento real dos consumidores ou das operações da Amazon.

2.4 Licença dos dados

A fonte utilizada informa a disponibilização do dataset sob a licença **Creative Commons Attribution 4.0 International (CC BY 4.0)**.

Essa licença permite o compartilhamento e a adaptação do material, desde que seja fornecida a devida atribuição ao autor/fonte original.

Fonte dos dados:

Kaggle — Amazon Sales Dataset — Rohit Kumar

https://www.kaggle.com/datasets/rohiteng/amazon-sales-dataset

A utilização dos dados neste projeto é acompanhada da identificação da fonte original e da finalidade acadêmica/portfólio da análise.

---

3. Carga dos Dados (Etapa 4.2)

3.1 Processo de carga

O arquivo Amazon.csv foi utilizado como fonte inicial dos dados.

A primeira etapa consistiu na disponibilização do arquivo no ambiente do Databricks. O arquivo foi armazenado em um Unity Catalog Volume, criado especificamente para os arquivos brutos do projeto.

A estrutura utilizada foi:

```
amazon_sales
│
├── bronze
│   └── raw_files
│       └── Amazon.csv
│
├── silver
│
└── gold
```

O arquivo foi então carregado para a camada Bronze utilizando a função read_files() do Databricks.

Após a validação inicial do conteúdo, os dados foram persistidos na tabela:

amazon_sales.bronze.sales_raw

3.2 Persistência da camada Bronze

A camada Bronze representa a primeira camada persistida do pipeline.

A tabela foi criada a partir do arquivo CSV:

```
CREATE OR REPLACE TABLE amazon_sales.bronze.sales_raw AS
SELECT *
FROM read_files(
   '/Volumes/amazon_sales/bronze/raw_files/Amazon.csv',
   format => 'csv',
   header => true,
   inferSchema => true
);
```

A camada Bronze tem como finalidade preservar os dados provenientes da fonte antes das transformações de negócio.

3.3 Referência ao código-fonte

Os scripts utilizados no projeto estão disponibilizados no repositório GitHub:

LINK GITHUB

Os scripts/notebooks disponibilizados permitem reproduzir as principais etapas de ingestão, transformação, modelagem e análise desenvolvidas no projeto.

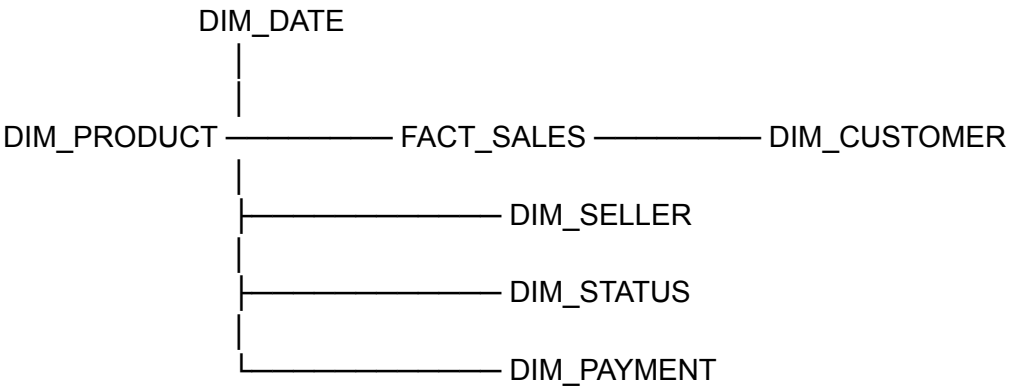
4. Modelagem e Catálogo de Dados (Etapa 4.3)

4.1 Estratégia de modelagem

Após a etapa de tratamento dos dados, foi adotado um **modelo dimensional em estrela (Star Schema)** para a camada Gold.

A escolha do modelo estrela foi feita devido à natureza analítica do projeto. O modelo permite separar as métricas transacionais das dimensões utilizadas para realizar filtros, agrupamentos e análises.

A estrutura principal é:



4.2 Granularidade da tabela fato

A granularidade definida para fact_sales é:

> Uma linha representa uma transação/pedido registrado na fonte.

Essa definição foi possível porque os OrderID apresentaram unicidade na base analisada.

A tabela fato concentra as principais métricas quantitativas e financeiras da transação.

4.3 Tabelas dimensionais

Foram criadas as seguintes dimensões:

dim_date

Dimensão calendário utilizada para análises temporais.

Principais atributos:

- DateKey
- Date
- Day
- Month
- MonthName
- Quarter
- Year
- DayOfWeek
- DayName

dim_product

Dimensão relacionada aos produtos.

Principais atributos:

- ProductKey
- ProductID
- ProductName
- Category
- Brand

Durante a análise de qualidade foi observado que um mesmo ProductID pode aparecer associado a diferentes combinações de categoria e marca. Por esse motivo, a dimensão preserva as combinações observadas na fonte em vez de assumir uma relação rígida entre ProductID, categoria e marca.

dim_customer

Dimensão relacionada aos clientes.

Principais atributos:

- CustomerKey
- CustomerID

- CustomerName
- City
- State
- Country

Também foi identificada variação de atributos associados a determinados CustomerID. Dessa forma, foram preservadas as combinações observadas na fonte.

dim_seller

Dimensão relacionada aos vendedores.

Principais atributos:

- SellerKey
- SellerID

dim_status

Dimensão dos status dos pedidos.

Principais atributos:

- StatusKey
- OrderStatus

dim_payment

Dimensão dos métodos de pagamento.

Principais atributos:

- PaymentKey
- PaymentMethod

4.4 Tabela fato

A principal tabela analítica é:

amazon_sales.gold.fact_sales

Ela contém:

Campo	Descrição
SalesKey	Chave substituta da transação

OrderID	Identificador original do pedido
DateKey	Chave da dimensão de data
ProductKey	Chave da dimensão de produto
CustomerKey	Chave da dimensão de cliente
SellerKey	Chave da dimensão de vendedor
StatusKey	Chave da dimensão de status
PaymentKey	Chave da dimensão de pagamento
Quantity	Quantidade vendida
UnitPrice	Preço unitário
Discount	Desconto
Tax	Imposto
ShippingCost	Custo de frete
TotalAmount	Valor total informado pela fonte

4.5 Catálogo de dados

Foi criado um catálogo de dados contendo, para os principais atributos:

- tabela de origem/destino;
- nome do campo;
- tipo de dado;
- descrição;
- domínio ou regra de validação;
- origem/linhagem do atributo.

Exemplo:

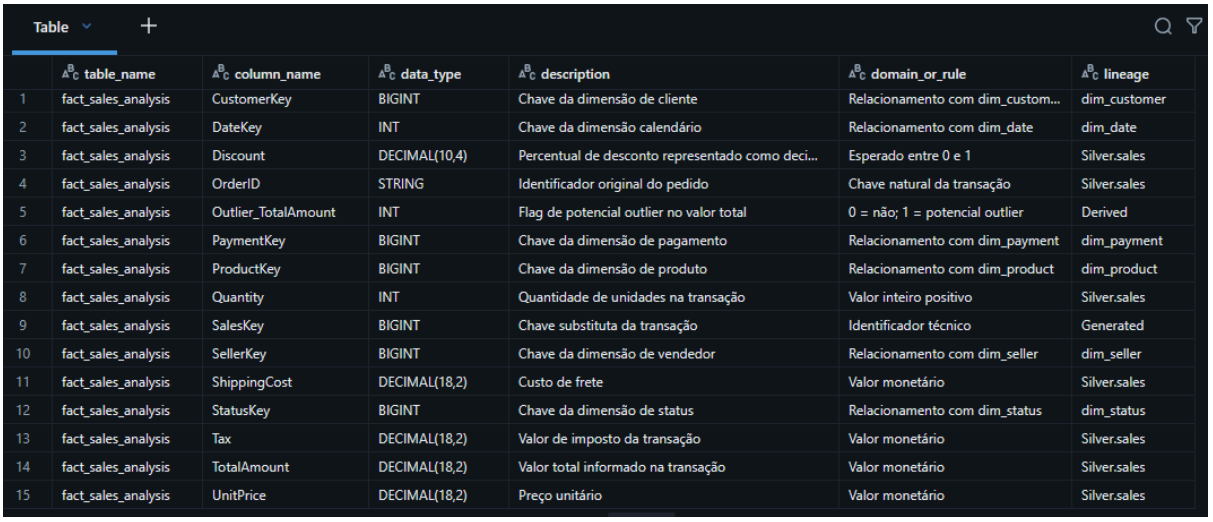
Tabela	Campo	Tipo	Descrição	Regra	Origem
fact_sales	OrderID	STRING	Identificador do pedido	Chave natural	Silver

fact_sales	Quantity	INT	Quantidade vendida	Valor positivo	Silver
fact_sales	UnitPrice	DECIMAL	Preço unitário	Valor monetário	Silver
fact_sales	Discount	DECIMAL	Percentual de desconto	0 a 1	Silver
fact_sales	Tax	DECIMAL	Imposto	Valor monetário	Silver
fact_sales	ShippingCost	DECIMAL	Custo de frete	Valor não negativo	Silver
fact_sales	TotalAmount	DECIMAL	Valor total da transação	Valor monetário	Silver

O catálogo completo foi implementado no ambiente Databricks na tabela:

amazon_sales.gold.data_catalog

Evidências



Table

	table_name	column_name	data_type	description	domain_or_rule	lineage
1	fact_sales_analysis	CustomerKey	BIGINT	Chave da dimensão de cliente	Relacionamento com dim_custom...	dim_customer
2	fact_sales_analysis	DateKey	INT	Chave da dimensão calendário	Relacionamento com dim_date	dim_date
3	fact_sales_analysis	Discount	DECIMAL(10,4)	Percentual de desconto representado como deci...	Esperado entre 0 e 1	Silver.sales
4	fact_sales_analysis	OrderID	STRING	Identificador original do pedido	Chave natural da transação	Silver.sales
5	fact_sales_analysis	Outlier_TotalAmount	INT	Flag de potencial outlier no valor total	0 = não; 1 = potencial outlier	Derived
6	fact_sales_analysis	PaymentKey	BIGINT	Chave da dimensão de pagamento	Relacionamento com dim_payment	dim_payment
7	fact_sales_analysis	ProductKey	BIGINT	Chave da dimensão de produto	Relacionamento com dim_product	dim_product
8	fact_sales_analysis	Quantity	INT	Quantidade de unidades na transação	Valor inteiro positivo	Silver.sales
9	fact_sales_analysis	SalesKey	BIGINT	Chave substituta da transação	Identificador técnico	Generated
10	fact_sales_analysis	SellerKey	BIGINT	Chave da dimensão de vendedor	Relacionamento com dim_seller	dim_seller
11	fact_sales_analysis	ShippingCost	DECIMAL(18,2)	Custo de frete	Valor monetário	Silver.sales
12	fact_sales_analysis	StatusKey	BIGINT	Chave da dimensão de status	Relacionamento com dim_status	dim_status
13	fact_sales_analysis	Tax	DECIMAL(18,2)	Valor de imposto da transação	Valor monetário	Silver.sales
14	fact_sales_analysis	TotalAmount	DECIMAL(18,2)	Valor total informado na transação	Valor monetário	Silver.sales
15	fact_sales_analysis	UnitPrice	DECIMAL(18,2)	Preço unitário	Valor monetário	Silver.sales

5. Pipeline de Dados (Etapa 4.4)

5.1 Arquitetura do pipeline

O projeto foi organizado segundo uma arquitetura baseada no conceito de **Medallion Architecture**.

O fluxo desenvolvido foi:



5.2 Organização das etapas

O pipeline foi dividido logicamente em diferentes etapas dentro do Databricks:

Etapa 1 — Ingestão

Responsável por carregar o arquivo CSV e criar a tabela:

amazon_sales.bronze.sales_raw

Etapa 2 — Tratamento

Os dados da Bronze foram transformados e persistidos em:

amazon_sales.silver.sales

As principais transformações foram:

- remoção de espaços desnecessários com TRIM;
- padronização dos campos textuais;
- conversão de valores monetários para DECIMAL;
- padronização do campo de desconto;
- preservação das datas;
- remoção do campo técnico _rescued_data da estrutura analítica final.

Etapa 3 — Modelagem

A partir da Silver foram construídas as dimensões e a tabela fato da camada Gold.

Etapa 4 — Qualidade e análise

Foi criada uma tabela adicional:

amazon_sales.gold.fact_sales_analysis

Essa tabela mantém os dados da tabela fato e adiciona indicadores de potenciais outliers.

5.3 SQL como linguagem principal

O pipeline foi desenvolvido predominantemente em **SQL**, utilizando os recursos nativos do Databricks.

A utilização de SQL permitiu realizar:

- ingestão;
- criação das tabelas;
- transformação;
- tipagem;
- validações;
- modelagem dimensional;
- identificação de outliers;
- agregações analíticas.

Dessa forma, não foi necessário utilizar Python para as principais etapas do pipeline.

6. Qualidade de Dados (Etapa 4.5)

A qualidade dos dados foi avaliada considerando os principais aspectos de:

- completude;
- unicidade;
- consistência;
- validade;
- integridade;
- valores extremos/outliers.

6.1 Completude

A análise inicial identificou **ausência de valores nulos** nos 20 atributos originais.

Foram realizadas validações específicas para campos importantes, como:

- OrderID;
- OrderDate;
- CustomerID;
- ProductID;
- Quantity;
- UnitPrice;
- Discount;
- TotalAmount.

Não foram identificados registros nulos nesses atributos.

6.2 Unicidade

Foram identificados:

- 100.000 registros;
- 100.000 OrderID distintos;
- nenhum registro completamente duplicado.
- Dessa forma, não foi necessário excluir registros por duplicidade.
- A unicidade do OrderID também foi utilizada para definir a granularidade da tabela fato.

6.3 Tipagem e padronização

Na passagem da Bronze para a Silver foram realizadas transformações para garantir maior consistência dos dados.

Entre elas:

- campos textuais tratados com TRIM;
- valores monetários convertidos para DECIMAL;
- desconto armazenado em formato decimal;

- campos numéricos mantidos em tipos apropriados;
- manutenção da data como tipo DATE.

A tabela resultante foi:

amazon_sales.silver.sales

6.4 Validação dos valores

Foram aplicadas regras para identificar valores potencialmente inválidos:

Quantity <= 0
UnitPrice < 0
Discount < 0 ou Discount > 1
Tax < 0
ShippingCost < 0
TotalAmount < 0

Essas validações foram utilizadas para avaliar a consistência dos atributos quantitativos antes da construção da camada analítica.

6.5 Consistência do TotalAmount

Foi realizada uma validação da composição do `TotalAmount`.

A fórmula observada nos dados é:

TotalAmount =
(Quantity × UnitPrice × (1 - Discount))
+ Tax
+ ShippingCost

A comparação entre o valor calculado e o valor informado na fonte demonstrou consistência dos registros dentro da tolerância de arredondamento utilizada.

Essa validação foi importante porque `TotalAmount` é uma das principais métricas utilizadas nas análises posteriores.

6.6 Inconsistências de dimensão

Durante a análise exploratória foram identificadas características importantes do dataset.

Produtos

O `ProductID` não apresentou uma relação determinística com todos os atributos de produto.

Embora o nome do produto apresente consistência, foram observadas diferentes combinações de `Category` e `Brand` para determinados `ProductID`.

Por isso, a modelagem da `dim_product` preservou as combinações efetivamente observadas nos dados.

Clientes

Também foram observadas diferentes combinações de nome e localização associadas a determinados `CustomerID`.

A dimensão de clientes, portanto, preserva as combinações observadas em vez de impor uma relação 1:1 que não é suportada pelo dataset.

Geografia

Foram identificadas inconsistências geográficas no dataset sintético, principalmente entre cidades e países.

Esse comportamento foi tratado como uma característica da fonte e não como uma informação que pudesse ser corrigida de forma confiável sem uma fonte externa de referência.

6.7 Outliers

A identificação de valores extremos foi realizada utilizando o método do **Intervalo Interquartil (IQR)**.

Para cada variável quantitativa foram calculados:

- primeiro quartil (Q1);
- terceiro quartil (Q3);
- IQR = Q3 - Q1;
- limite inferior = Q1 - 1,5 × IQR;
- limite superior = Q3 + 1,5 × IQR.

Foram avaliados:

- `Quantity`;

- `UnitPrice`;
- `Discount`;
- `Tax`;
- `ShippingCost`;
- `TotalAmount`.

Os registros identificados como potenciais outliers foram preservados.

Em vez de excluir ou alterar automaticamente esses registros, foi criada a tabela:

amazon_sales.gold.fact_sales_analysis

contendo flags:

Outlier_Quantity
Outlier_UnitPrice
Outlier_Discount
Outlier_Tax
Outlier_ShippingCost
Outlier_TotalAmount

Essa abordagem permite diferenciar **valor extremo** de **erro de dados**.

Como não existe uma regra de negócio externa estabelecendo limites máximos ou mínimos para essas variáveis e o dataset é sintético, não seria adequado assumir que todo outlier estatístico representa um erro.

Assim, os dados originais foram preservados e os registros extremos passaram a ser identificados por meio de indicadores.

6.8 Resumo do tratamento

Problema	**Tratamento**
Valores nulos	Validação; não foram identificados nulos
Registros duplicados	Validação; não foram identificadas duplicidades completas
OrderID duplicado	Validação; IDs únicos
Tipos de dados	Padronização na Silver
Espaços em textos	TRIM

Valores monetários	Conversão para DECIMAL
Desconto	Padronização e validação entre 0 e 1
TotalAmount	Validação matemática
Inconsistências de produto	Preservação das combinações observadas
Inconsistências de cliente	Preservação das combinações observadas
Inconsistências geográficas	Documentação da inconsistência
Outliers	Identificação por IQR e criação de flags
Dados sintéticos	Limitação documentada

7. Análise de Dados (Etapa 4.5)

Após a construção e validação das camadas Bronze, Silver e Gold, foram realizadas análises destinadas a responder às oito perguntas de negócio definidas inicialmente.

7.1 Evolução das vendas ao longo do tempo

A primeira análise avaliou a evolução temporal das vendas, considerando:

- número de pedidos;
- quantidade de unidades;
- valor transacionado;
- ticket médio.

A análise foi realizada utilizando a `fact_sales_analysis` em conjunto com a `dim_date`.

A análise permite identificar períodos de maior e menor atividade comercial e observar a evolução do ticket médio ao longo do período analisado.

Table

	Year	Month	MonthName	pedidos	unidades	valor_transacionado	ticket_medio
1	2020	1	January	1730	5225	1637069.40	946.28
2	2020	2	February	1490	4343	1339388.21	898.92
3	2020	3	March	1685	5050	1587125.66	941.91
4	2020	4	April	1692	5156	1588347.29	938.74
5	2020	5	May	1672	5061	1533834.17	917.36
6	2020	6	June	1633	4883	1500269.29	918.72
7	2020	7	July	1687	5061	1552981.94	920.56
8	2020	8	August	1783	5439	1640874.93	920.29
9	2020	9	September	1679	5023	1554682.21	925.96
10	2020	10	October	1647	4908	1515403.62	920.10
11	2020	11	November	1639	4866	1502232.24	916.55
12	2020	12	December	1729	5193	1577655.06	912.47
13	2021	1	January	1764	5255	1575253.23	893.00
14	2021	2	February	1516	4524	1425365.99	940.22
15	2021	3	March	1620	4894	1484165.89	916.15

7.2 Categorias, marcas e produtos

A segunda análise avaliou a distribuição das vendas por:

- categoria;
- marca;
- produto.

Foram utilizados como indicadores:

- quantidade de pedidos;
- unidades vendidas;
- valor transacionado;
- ticket médio.

Devido às inconsistências identificadas entre `ProductID`, categoria e marca, os resultados devem ser interpretados considerando a estrutura observada no dataset.

Table

	Category	pedidos	unidades	valor_transacionado	ticket_medio
1	Electronics	16853	50696	15584217.18	924.71
2	Sports & Outdoors	16804	50543	15345571.88	913.21
3	Books	16752	49981	15261837.01	911.05
4	Clothing	16439	49523	15253397.50	927.88
5	Toys & Games	16542	49773	15216684.99	919.88
6	Home & Kitchen	16610	49624	15163939.36	912.94

Table

	Brand	pedidos	unidades	valor_transacionado
1	CoreTech	10127	30430	9343720.59
2	KiddoFun	10077	30168	9324749.55
3	ReadMore	10204	30421	9278406.63
4	UrbanStyle	9854	30104	9249027.45
5	Zenith	9990	30058	9239960.39
6	Apex	9937	29955	9147604.72
7	NexPro	9962	29791	9078824.97
8	FitLife	10147	30121	9061444.68
9	BrightLux	9907	29616	9056816.11
10	HomeEase	9795	29476	9045092.83

Table

	ProductID	ProductName	Category	Brand	pedidos	unidades	valor_transacionado
1	P00034	Desk Organizer	Clothing	KiddoFun	58	166	58059.53
2	P00028	Jeans	Sports & Outdoors	Apex	50	156	56329.85
3	P00047	Memory Card 128GB	Home & Kitchen	HomeEase	53	162	55874.05
4	P00023	Cookware Set	Books	KiddoFun	43	147	53889.96
5	P00043	HDMI Cable 2m	Electronics	Zenith	48	154	53200.52
6	P00019	LED Desk Lamp	Sports & Outdoors	Apex	52	167	52494.29
7	P00008	4K Monitor	Sports & Outdoors	ReadMore	59	181	52452.39
8	P00004	USB-C Charger	Sports & Outdoors	Zenith	47	141	52155.04
9	P00007	Mechanical Keyboard	Home & Kitchen	HomeEase	43	144	51373.57
10	P00019	LED Desk Lamp	Toys & Games	CoreTech	43	155	51046.67
11	P00012	Noise Cancelling Headphon...	Books	ReadMore	46	145	50848.87
12	P00020	Office Chair	Clothing	ReadMore	53	164	50377.28
13	P00045	Phone Tripod	Clothing	FitLife	43	141	50333.48
14	P00028	Jeans	Sports & Outdoors	Zenith	41	134	50145.01
15	P00040	Microphone	Books	NexPro	53	153	49580.23

7.3 Descontos

Os pedidos foram agrupados em faixas de desconto:

0%
0–10%
10–20%
20–30%
30%+

Foram comparados:

- número de pedidos;
- unidades vendidas;
- valor transacionado;
- ticket médio;
- desconto médio.

Os resultados representam associações observadas no dataset e não permitem afirmar causalidade entre desconto e volume de vendas.



Table

	faixa_desconto	pedidos	unidades	valor_transacionado	ticket_medio	desconto_medio_percentual
1	0%	40246	120977	39759304.30	987.91	0.00
2	0-10%	34799	104281	32145250.64	923.74	7.14
3	10-20%	17980	53880	14752593.80	820.50	17.21
4	20-30%	6975	21002	5168499.18	741.00	26.43

7.4 Preço, quantidade, desconto, impostos e frete

Foram analisadas as principais variáveis financeiras e quantitativas das transações.

Também foram utilizadas correlações entre variáveis para avaliar relações estatísticas.

A análise deve ser interpretada como uma descrição estatística das transações. Correlação não implica causalidade.

A validação realizada anteriormente também demonstrou que o `TotalAmount` é matematicamente compatível com os componentes de preço, quantidade, desconto, imposto e frete registrados na fonte.



Table

	quantidade_media	preco_medio	desconto_medio_percentual	imposto_medio	frete_medio	total_medio	total
1	3	302.91	7.42	68.47	7.41	918.26	

7.5 Clientes e localização

As vendas foram analisadas por:

- país;
- estado;
- cidade;
- cliente.

Foram considerados principalmente:

- número de pedidos;
- valor transacionado;
- quantidade de unidades;
- ticket médio.

Resultado:

Table

	Country	State	pedidos	clientes	valor_transacionado
1	United States	TX	17334	14662	15897488.53
2	United States	CA	14014	12277	12783662.94
3	India	TX	3797	3648	3503209.66
4	United States	NC	3606	3467	3311877.73
5	United States	PA	3543	3409	3287459.93
6	United States	FL	3594	3479	3281693.36
7	United States	IL	3507	3402	3268618.39
8	United States	IN	3469	3364	3246583.55
9	United States	CO	3462	3334	3240143.04
10	United States	OH	3521	3392	3237947.84
11	United States	WA	3504	3373	3224396.33
12	United States	DC	3560	3433	3197914.23
13	United States	AZ	3503	3361	3182720.17
14	United States	NY	3441	3309	3149542.46
15	India	CA	3041	2959	2832945.31

	CustomerID	CustomerName	pedidos	unidades	valor_transacionado	ticket_medio
1	CUST010696	Pooja Patel	2	10	5436.04	2718.02
2	CUST035973	Neha Sharma	2	9	5124.43	2562.22
3	CUST009614	Vikas Mehta	2	9	5003.65	2501.83
4	CUST018720	Arjun Kapoor	2	9	4773.18	2386.59
5	CUST022824	Pooja Joshi	2	8	4755.48	2377.74
6	CUST008882	Sneha Reddy	2	9	4730.47	2365.24
7	CUST022031	Priya Kapoor	2	7	4266.02	2133.01
8	CUST031449	Vivaan Kapoor	2	8	4253.27	2126.64
9	CUST005523	Sahil Patel	2	10	4239.18	2119.59
10	CUST047013	Arjun Kumar	2	8	4222.62	2111.31
11	CUST046121	Sunita Joshi	2	9	4207.74	2103.87
12	CUST049666	Aditya Gupta	2	8	4189.02	2094.51
13	CUST041944	Mohit Mehta	2	10	4171.02	2085.51
14	CUST040270	Arjun Gupta	2	10	4138.60	2069.30
15	CUST029051	Pooja Sharma	2	8	4134.32	2067.16

7.6 Status dos pedidos

Os diferentes status de pedidos foram comparados considerando:

- quantidade de pedidos;
- percentual dos pedidos;
- unidades;
- valor transacionado;
- ticket médio.

É importante destacar que `TotalAmount` representa o valor informado na transação. Portanto, ele não deve ser interpretado automaticamente como receita contábil realizada, especialmente em situações envolvendo cancelamentos ou devoluções.

	OrderStatus	pedidos	percentual_pedidos	unidades	valor_transacionado	ticket_medio
1	Delivered	74628	74.63	223759	68372677.10	916.18
2	Shipped	15192	15.19	45660	14083628.99	927.04
3	Pending	4103	4.10	12338	3737556.98	910.93
4	Returned	3049	3.05	9141	2780662.46	911.99
5	Cancelled	3028	3.03	9242	2851122.39	941.59

7.7 Métodos de pagamento

Os métodos de pagamento foram analisados considerando:

- número de pedidos;
- unidades vendidas;
- valor transacionado;
- ticket médio;
- participação no valor total.

Table

	PaymentMethod	pedidos	unidades	valor_transacionado	ticket_medio	participacao_valor_percentual
1	Credit Card	35038	105046	32122158.69	916.78	34.98
2	Debit Card	20024	60242	18538678.53	925.82	20.19
3	UPI	15066	45218	13896028.55	922.34	15.13
4	Amazon Pay	15017	45099	13697498.42	912.13	14.92
5	Net Banking	9927	29699	9055674.57	912.23	9.86
6	Cash on Delivery	4928	14836	4515609.16	916.32	4.92

7.8 Desempenho dos vendedores

Por fim, os vendedores foram comparados considerando:

- número de pedidos;
- unidades vendidas;
- valor transacionado;
- ticket médio.

Também podem ser utilizados os status dos pedidos para avaliar a distribuição de cancelamentos e devoluções.

	SellerID	pedidos	unidades	valor_transacionado	ticket_medio
1	SELL00806	67	234	71283.67	1063.94
2	SELL00440	61	197	71062.59	1164.96
3	SELL01225	61	204	70785.92	1160.42
4	SELL00709	69	223	70491.92	1021.62
5	SELL00221	65	211	70446.50	1083.79
6	SELL01122	67	217	69469.40	1036.86
7	SELL00994	61	199	69400.06	1137.71
8	SELL00536	70	220	69248.00	989.26
9	SELL00371	65	203	69118.88	1063.37
10	SELL00812	68	212	68591.86	1008.70
11	SELL01922	66	204	68290.28	1034.70
12	SELL01164	60	199	67890.28	1131.50
13	SELL01584	69	213	67862.72	983.52
14	SELL01813	63	190	67855.92	1077.08
15	SELL00100	62	208	67540.22	1089.36

Table

	SellerID	pedidos	valor_transacionado	valor_cancelado_ou_devolvido
1	SELL00806	67	71283.67	7833.86
2	SELL00440	61	71062.59	7206.49
3	SELL01225	61	70785.92	4223.49
4	SELL00709	69	70491.92	7445.33
5	SELL00221	65	70446.50	4299.78
6	SELL01122	67	69469.40	7867.32
7	SELL00994	61	69400.06	3322.28
8	SELL00536	70	69248.00	5351.53
9	SELL00371	65	69118.88	3915.92
10	SELL00812	68	68591.86	5423.42
11	SELL01922	66	68290.28	0.00
12	SELL01164	60	67890.28	6964.22
13	SELL01584	69	67862.72	4603.06
14	SELL01813	63	67855.92	4681.41
15	SELL00100	62	67540.22	4514.13

---

8. Limitações da Análise

Os resultados devem ser interpretados considerando algumas limitações importantes da fonte.

Dados sintéticos

O dataset é sintético e, portanto, não há garantia de que os padrões encontrados representem o comportamento real de consumidores, vendedores ou operações de e-commerce.

Ausência de margem

A base não possui custo dos produtos ou margem de contribuição. Portanto, o projeto não permite realizar uma análise de lucratividade.

Descontos

As análises de desconto identificam associações, mas não permitem estabelecer relações causais.

Dimensões

Foram identificadas inconsistências entre IDs e atributos descritivos de produtos e clientes. Essas inconsistências foram documentadas e preservadas em vez de serem corrigidas por suposições.

---

9. Autoavaliação

9.1 Cumprimento dos objetivos

O objetivo inicial do projeto era construir uma estrutura de dados confiável e organizada para transformar dados transacionais brutos em informações adequadas para análise de negócio.

Esse objetivo foi atingido por meio da construção de um pipeline dividido em camadas:

Fonte
↓
Bronze
↓
Silver
↓
Gold
↓
Análise

Foi possível implementar a ingestão dos dados, tratamento, tipagem, validações de qualidade, modelagem dimensional, documentação dos atributos e consultas analíticas orientadas às perguntas de negócio.

A construção da fact_sales_analysis também permitiu incorporar uma etapa específica de identificação de potenciais outliers, sem alterar ou excluir automaticamente os dados originais.

9.2 Principais dificuldades

Uma das dificuldades encontradas foi a própria etapa de ingestão dos dados no Databricks. A tentativa inicial de realizar a leitura diretamente a partir de uma URL do GitHub apresentou limitações no ambiente utilizado. Como alternativa, o arquivo foi disponibilizado em um Unity Catalog Volume e posteriormente carregado para a camada Bronze.

Outra dificuldade foi lidar com inconsistências internas do dataset.

A análise demonstrou que determinados identificadores não apresentam relações completamente determinísticas com seus atributos descritivos. Isso exigiu uma decisão de modelagem diferente de simplesmente assumir que cada ID representava uma entidade única e imutável.

9.3 Aprendizados

Um dos principais aprendizados foi compreender que um pipeline de dados não consiste apenas em carregar e transformar informações. A confiabilidade da camada analítica depende também da definição da granularidade, das regras de qualidade, da documentação e da compreensão das limitações da fonte.

10. Conclusão

O projeto demonstrou a construção de um fluxo completo de dados no Databricks, partindo de um arquivo transacional bruto e chegando a uma camada estruturada para análise.

A utilização das camadas Bronze, Silver e Gold permitiu separar as responsabilidades de ingestão, tratamento e disponibilização analítica.

A modelagem dimensional possibilitou organizar os dados em uma estrutura adequada para consultas analíticas, enquanto as etapas de qualidade permitiram identificar limitações, inconsistências e potenciais valores extremos presentes na fonte.

Por fim, as oito perguntas de negócio orientaram a construção das análises, garantindo que o pipeline não fosse desenvolvido apenas como um exercício técnico, mas como uma solução voltada à transformação de dados em informações úteis para o negócio.

O projeto também evidencia a importância de documentar não apenas as transformações realizadas, mas também as limitações e decisões tomadas durante o processo. Dessa forma, a solução torna-se mais transparente, reprodutível e preparada para futuras evoluções.